

Reporte de Resultados — K-means desde cero

Clustering del dataset Iris con una implementación manual del algoritmo K-means (sin usar librerías de aprendizaje máquina).

1. Dataset de entrenamiento y de prueba

Se utilizó el dataset público **Iris** (150 muestras, 4 características numéricas: sepal_length, sepal_width, petal_length, petal_width; 3 clases: setosa, versicolor, virginica). Se aplicó un split **estratificado 80% / 20%: 120 muestras para entrenamiento y 30 muestras para prueba**, manteniendo en ambos conjuntos la misma proporción de especies que el dataset original. Las características se estandarizaron (media 0, desviación 1) usando únicamente las estadísticas del set de entrenamiento.

Como K-means es un algoritmo no supervisado, las etiquetas reales no se usaron para entrenar: el modelo se ajustó únicamente con las 4 características. Después del entrenamiento, a cada cluster se le asignó la especie real mayoritaria entre los puntos de entrenamiento que cayeron en él, y ese mapeo se reutilizó tal cual para traducir los clusters del set de prueba a especies, sin volver a usar las etiquetas de prueba en el proceso.




Figura 1. Método del codo: la inercia baja notoriamente hasta $k=3$ y luego se aplana, lo que justifica usar $k=3$ (consistente con las 3 especies reales).

2. Matriz de confusión (set de prueba)

Filas = especie real, columnas = especie predicha (cluster traducido con el mapeo aprendido en entrenamiento).

	setosa	versicolor	virginica
setosa	10	0	0
versicolor	0	8	2
virginica	0	1	9

3. Métricas de desempeño (set de prueba)



Accuracy global: 0.9000

Clase	Precision	Recall	F1-score
setosa	1.0000	1.0000	1.0000
versicolor	0.8889	0.8000	0.8421
virginica	0.8182	0.9000	0.8571
Macro avg	0.9024	0.9000	0.8997

Precision, recall y F1-score se calcularon a partir de la matriz de confusión de forma manual (verdaderos/falsos positivos y negativos por clase), sin usar funciones de librerías de métricas.

4. Visualización de los clusters

Proyección sobre petal_length y petal_width (las dos características con mayor poder de separación entre especies). Color = cluster asignado por el modelo; forma del marcador = especie real; X negra = centroides.



5. Análisis y conclusión

El modelo alcanzó un **accuracy de 90.0%** sobre el set de prueba al traducir los clusters encontrados a especies reales. La especie **setosa** se separó de forma perfecta (precision y recall de 1.0), lo cual es esperado porque en el espacio de características es linealmente separable del resto. La mayor parte del error ocurre entre **versicolor** y **virginica**, que se traslapan parcialmente en petal_length/petal_width; esto es consistente con el comportamiento reportado en la literatura para este dataset y refleja una limitación esperable de K-means: al agrupar por cercanía euclidiana a un centroide (clusters aproximadamente esféricos), no puede capturar fronteras de decisión curvas o solapamientos entre clases vecinas.

El método del codo confirma que $k=3$ es una elección razonable, lo cual coincide con el número real de especies en el dataset, aunque en un escenario puramente no supervisado (sin conocer las clases reales) esta elección se basaría únicamente en la forma de la curva de inercia. En general, los resultados muestran que K-means, sin ninguna supervisión durante el entrenamiento, es capaz de recuperar la estructura de clases del dataset Iris con un desempeño alto, confirmando que las especies tienen una separación natural en el espacio de características utilizado.